

파인튜닝 (Fine-Tuning)

인공지능 명예학회

2024.05.09

Contents

1. 파인튜닝이란?

4. 파인튜닝의 세가지 방법

2. 파인튜닝이 필요한 이유

5. 주의사항

3. 파인튜닝 방법

6. 응용 분야

1. 파인튜닝이란?

파인튜닝은 딥러닝 모델을 개선하고 성능을 향상시키는 과정 중 하나이다.

이 과정은 사전 훈련된 (pre-trained) 모델을 가져와 특정 작업 또는 데이터에 맞게 조정하는 것을 의미한다.

파인튜닝을 기존 모델의 가중치를 업데이트를 하거나 새로운 데이터로 모델을 훈련시켜 작업에 더 적합하게 만든다.

예를 들어, 새로운 요리 레시피를 배운 후 그 요리를 자신의 입맛에 맞게 약간 변형하는 것과 비슷하다.

이 과정을 통해 기존의 모델이 더 정교하고 특화된 작업 수행 능력을 갖추게 된다.

사전 학습된 모델 전체를 조정한 정도에 따라 Full Fine-Tuning과 Repurposing 두 가지 방법으로 분류할 수 있다.

2. 파인튜닝이 필요한 이유

- 특정 도메인이나 작업에 최적화:** 사전 학습된 인공지능 모델은 대규모 데이터셋으로 학습되어 일반적인 작업에 적합하지만, 특정 도메인이나 작업에 대한 성능은 제한적일 수 있다. 파인튜닝을 통해 모델을 특정 작업에 맞게 조정하여 성능을 향상시킬 수 있다.
 - 자원 및 시간 절약:** 사전 학습된 모델을 기반으로 파인튜닝하면, 작은 양의 데이터와 상대적으로 짧은 학습 시간으로도 좋은 성능을 얻을 수 있다. 이로 인해 전체 학습 과정에서 필요한 자원과 시간을 절약할 수 있다.
 - 새로운 데이터에 대한 적응:** 인공지능 모델은 새로운 입력 내용에 따라 기존 지식을 조정하며 과제를 수행할 수 있도록 지원하는 기술이다. 파인튜닝을 통해 모델은 새로운 데이터에 더 잘 적응하고, 그에 따른 예측이나 추론 성능이 향상된다.
-

3. 파인튜닝하는 방법 : Full Fine-tuning

전체 파인튜닝은 모든 모델 매개변수를 포함하여 사전 학습된 모델 전체를 파인튜닝하는 작업을 의미한다. 이 방법에서는 사전 학습된 모델의 모든 레이어와 매개 변수가 업데이트되고 최적화되어 대상 작업의 요구 사항에 맞게 조정된다.

이 방법은 일반적으로 작업과 사전 학습된 모델 사이에 큰 차이가 있거나 작업에서 모델의 유연성과 적응성이 높아야 하는 경우에 적합하다. 전체 파인튜닝에서는 상당한 리소스와 시간이 필요하지만 그만큼 더 나은 성능을 얻을 수 있다.

3. 파인튜닝하는 방법 : Repurposing

Repurposing은 사전 학습된 모델의 하위 레이어를 그대로 유지하면서 모델의 상위 레이어 또는 선택된 몇 개의 레이어를 파인튜닝하는 것을 의미한다. 이 방법의 목적은 사전 학습된 모델에 대한 일반적인 지식을 유지하면서 최상위 레이어를 특정 작업에 적용하는 것이다.

이 방법은 대상 작업과 사전 학습된 모델 사이에 특정 유사성이 있거나 작업 데이터셋이 작은 경우에 적합한 경우가 많다. Repurposing은 몇 개의 레이어만 업데이트되므로 Full Fine-tuning에 비해 필요한 리소스와 시간이 적지만 경우에 따라 약간의 성능 저하가 발생할 수 있다.

3. Full Fine-tuning과 Repurposing


Full Fine-Tuning과 Repurposing간의 선택은 **작업의 특성**과 **사용 가능한 리소스**에 따라 달라진다.

작업과 사전 학습된 모델 사이에 큰 차이가 있거나 높은 적응성이 필요한 경우 **Full Fine-tuning**이 더 적합하다.

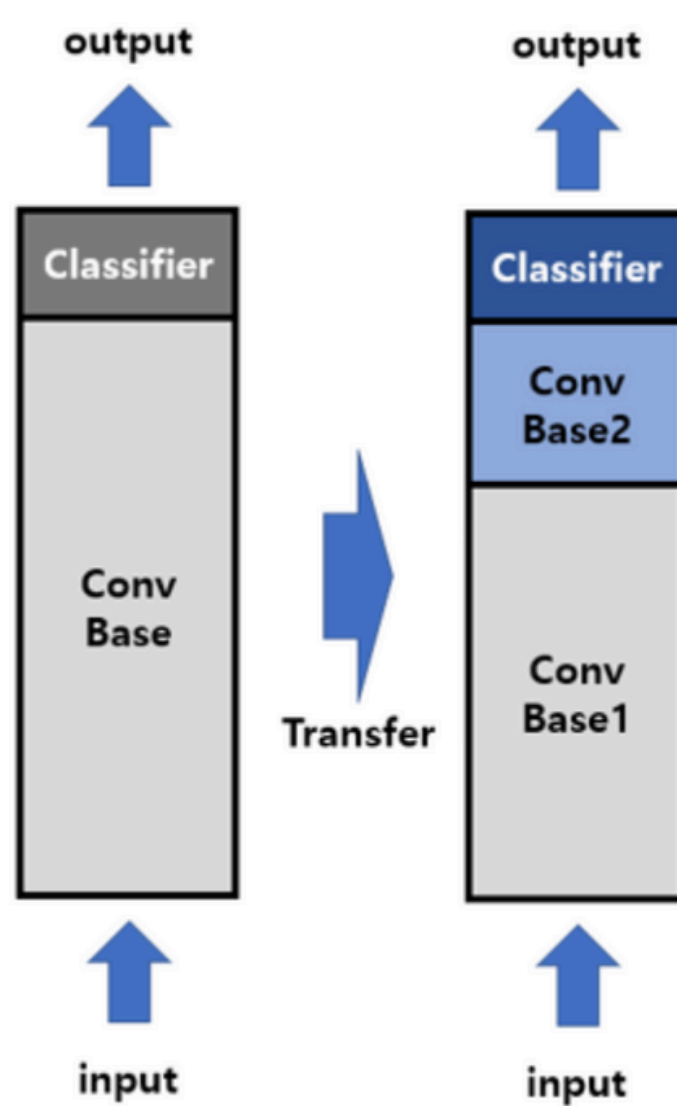
작업이 사전학습된 모델과 유사성이 높거나 리소스가 제한적일 경우 **Repurposing**이 더 나은 선택일 수 있다.

실제 적용에서는 최적의 성능을 달성하기 위해 작업 요구 사항 및 실험 결과를 기반으로 적절한 파인튜닝 방법을 선택해야한다.

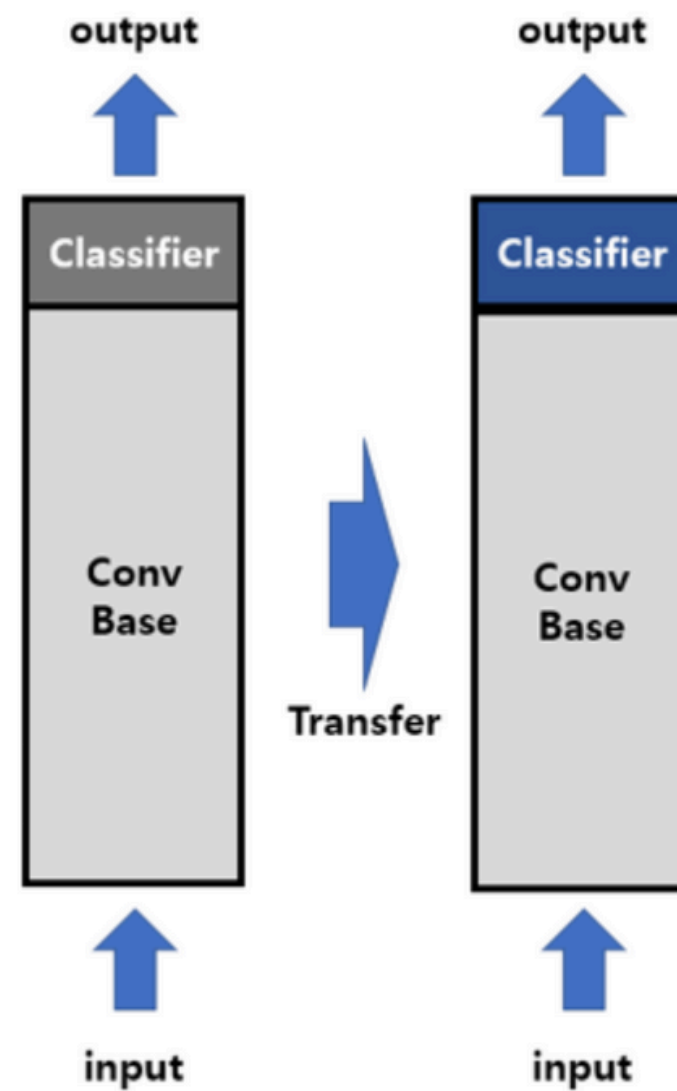
4. 파인튜닝 세가지 방법



Strategy 1
: 모델 전체를 학습하는 경우




Strategy 2
: 일부만 학습시키는 경우



Strategy 3
: 학습 과정 없이 사용하는 경우

상황 1. 데이터셋의 크기가 **크고** 사전학습 때 사용한 데이터셋과의 유사성이 **작을** 때

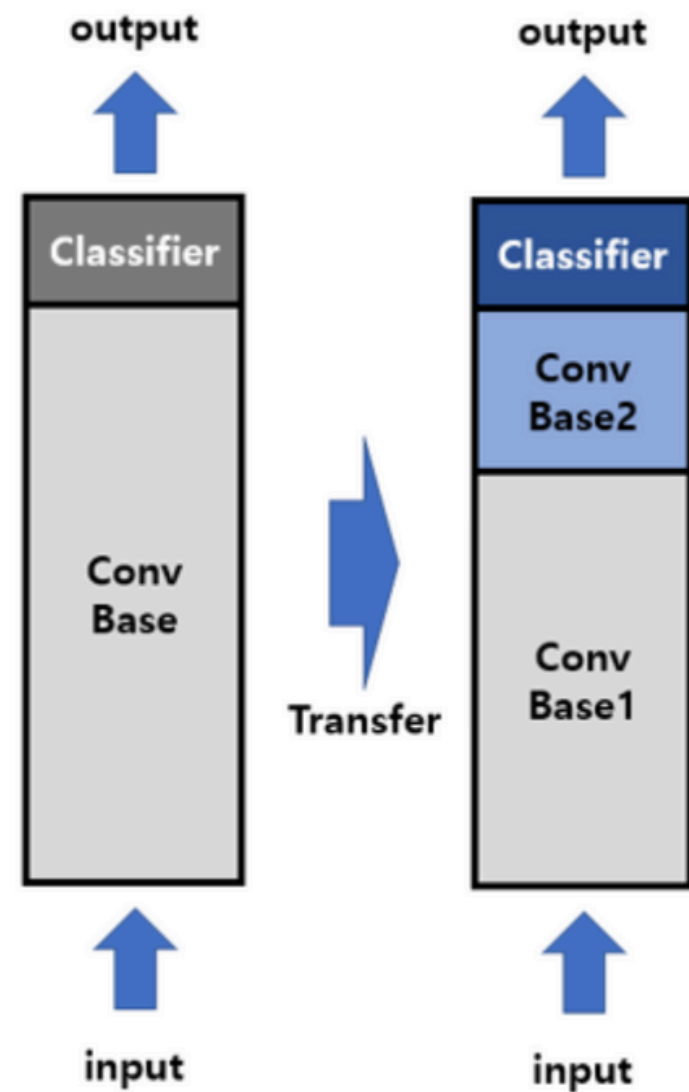


Strategy 1
: 모델 전체를 학습하는 경우

- 이 경우에는 전체 모델을 새로 학습하는 편이 좋음
- 데이터셋의 크기가 크기 때문에 모델의 파라미터를 모두 사용해도 해당 데이터셋에 overfitting(과적합) 되지 않을 확률이 높음
- 컴퓨팅 연산 능력이 받쳐준다면 모델을 처음부터 해당 데이터셋의 방향으로 학습시키는 것이 가능함

=> 전체 모델을 새로 학습

상황 2. 데이터셋의 크기가 **크고** 사전학습 때 사용한 데이터셋과의 유사성이 **높을** 때

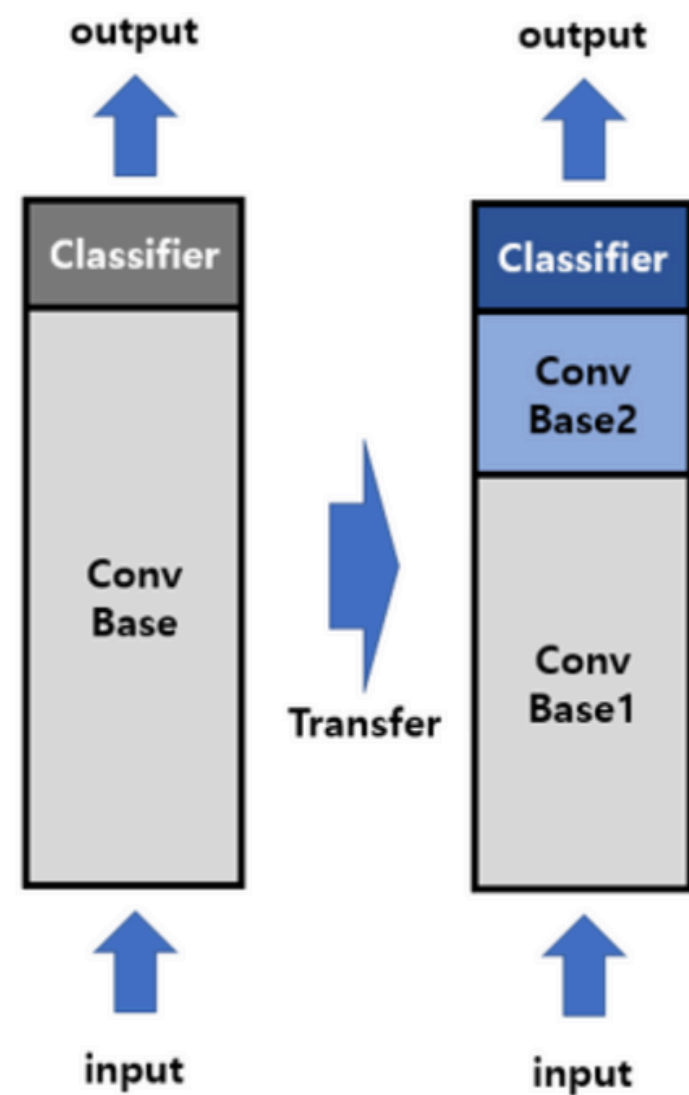


Strategy 2
: 일부만 학습시키는 경우

- 이 경우에는 사실 어떤 선택을 해도 상관없는데, 효과적인 전략을 찾자면 사전 학습된 모델의 일부를 freezing하고 남은 레이어를 학습시키는 전략이 유효할 수 있음
- 데이터셋이 여전히 크기 때문에 overfitting(과적합) 문제가 발생할 확률은 적지만, 데이터의 유사도가 높기 때문에 사전 학습된 모델이 이미 학습한 일반화된 지식을 충분히 활용할 수 있음
- 사전 학습된 모델의 레이어를 모두 학습하는 것이 오히려 일반화된 지식 활용을 방해할 수 있음

**Convolutional base 일부분 고정,
나머지 계층과 Classifier 새로 학습**

상황 3. 데이터셋의 크기가 작고 사전학습 때 사용한 데이터셋과의 유사성이 작을 때




Strategy 2
: 일부만 학습시키는 경우

- 사전학습한 모델의 도움을 충분히 받지 못할 수 있는데 최선의 전략을 찾는다면, 유사성이 작더라도 데이터셋의 크기가 작기 때문에 사전 학습한 모델의 일반화된 지식을 활용해야함
- 따라서 상황2와 동일하게 사전학습된 모델의 일부를 freezing하고 남은 레이어를 학습시키는 전략이 유효할 수 있음
- 만약 모델을 freezing하지 않는다면, 데이터셋이 너무 작기 때문에 쉽게 overfitting(과적합)이 발생할 수 있음

**Convolutional base 일부분 고정,
나머지 계층과Classifier 새로 학습**

상황 4. 데이터셋의 크기가 작고 사전학습 때 사용한 데이터셋과의 유사성이 높을 때



Strategy 3
: 학습 과정 없이 사용하는 경우

- 이 경우에는 데이터셋이 작지만 유사성이 높기 때문에 모델 전체를 freezing 하고 새로운 레이어를 추가하여 학습하는 전략이 효과적일 수 있음
- 데이터셋 간 유사성이 높지만 데이터셋이 작기 때문에 사전학습한 모델이 이미 학습한 지식을 최대한 활용하고 추가로 학습할 파라미터 수를 최소화하는 식으로 전략을 설정해야함
- 또는 성능 비교를 위해 사전학습한 모델의 레이어 일부를 점점 unfreezing 하는 전략들을 시도할 수 있음

Convolutional base부분을 특징 추출기로서 사용하고
Classifier 부분만 변경해서 학습시킴

5. 파인튜닝 주의사항

1. 데이터 품질 및 양

- 데이터 다양성 : 데이터가 한쪽으로 편향되어 있으면 모델의 일반화 능력이 저하될 수 있기 때문에 파인튜닝에 사용하는 데이터 세트는 다양한 예시를 포함해야한다.
- 충분한 데이터 : 파인튜닝에는 일반적으로 많은 양의 데이터가 필요하다. 데이터가 부족하면 모델이 과적합될 위험이 있다.

2. 과적합 방지

- 적절한 모델 크기 : 너무 큰 모델은 과적합될 위험이 있다. 모델의 크기와 파라미터 수를 데이터 양과 복잡도에 맞게 조절해야 한다.
- 정규화 기법 : 드롭아웃이나 L1/L2 정규화와 같은 기법을 사용하여 과적합을 방지할 수 있다.
- 조기 종료 : 검증 세트의 성능이 더 이상 향상되지 않을 때 학습을 중단하는 것이 효과적이다.

3. 하이퍼파라미터 튜닝

- 적절한 학습률 : 너무 높은 학습률은 모델을 불안정하게 만들 수 있고, 너무 낮은 학습률은 학습이 너무 느리게 진행될 수 있다.
 - 배치 크기와 에포크 수 : 적절한 배치 크기와 에포크 수를 설정하여 학습 과정을 최적화해야한다.
-

5. 파인튜닝 주의사항

4. 편향과 공정성

- 데이터 편향 : 데이터에 편향이 있으면 모델의 예측도 편향될 수 있습니다. 데이터 세트를 신중하게 검토하고 편향을 줄이려는 노력이 필요하다.
- 공정성 : 모델이 모든 사용자와 그룹에게 공정하게 동작하도록 해야 한다. 모델의 예측이 특정 그룹을 차별하지 않도록 주의해야 한다.

5. 평가 지표 선택

- 적절한 평가 지표 : 모델의 성능을 평가할 때 적절한 지표를 선택하는 것이 중요하다. 예를 들어 분류 문제에서는 정확도뿐만 아니라 정밀도, 재현율, F1 점수 등도 고려해야 할 수 있다.

6. 리소스와 비용

- 계산 리소스 : 파인튜닝은 상당한 계산 리소스를 필요로 할 수 있다. 사용 가능한 리소스와 비용을 고려하여 파인튜닝 전략을 계획해야 한다.

파인튜닝은 강력하지만 복잡한 과정이다. 주의 깊은 계획, 철저한 검증, 그리고 지속적인 모니터링을 통해 모델의 성능과 안정성을 최대한 활용할 수 있다.

6. 파인튜닝의 응용 분야

1. 자연어 처리 (NLP) : 사전 훈련된 언어 모델을 파인튜닝하여 특정 언어 작업, 감정 분석, 기계 번역 등을 개선한다.
 2. 컴퓨터 비전 : 이미지 분류, 객체 감지, 얼굴 인식 등의 작업에 대한 모델을 조정하여 성능을 향상시킨다.
 3. 오디오 처리 : 음성 인식 및 음성 생성 모델을 특정 언어 또는 환경에 맞게 파인튜닝한다.
 4. 의료 이미지 분석 : 의료 이미지를 분석하기 위한 딥러닝 모델을 의료 전문 분야에 맞게 조정한다.
-